

Πρώτη Φάση Προγραμματιστικής Εργασίας στην Σημασιολογική Ανάλυση

Εφαρμογή και Αξιολόγηση Κλασικών Μοντέλων Ανάκτησης με Elasticsearch και TREC Evaluation

Στόχος της εργασίας μας ήταν η εξοικείωση με την μηχανή αναζήτησης *Elasticsearch* την οποία και χρησιμοποιήσαμε για να επεξεργαστούμε τα κείμενα και να δημιουργήσουμε το κατάλληλο ευρετήριο πάνω στο οποίο τρέξαμε τα ερωτήματα που μας ζητούνταν. Επίσης ασχοληθήκαμε και με το εργαλείο αξιολόγησης *trec_eval*, το οποίο μας έδωσε *map* και *precision* για τις απαντήσεις μας και έτσι μπορέσαμε να τις αξιολογήσουμε. Συγκεκριμένα βήμα-βήμα:

1. Αρχικά εγκαταστήσαμε την *elasticsearch* σύμφωνα με τις οδηγίες της διδάσκουσας και την τρέξαμε σε ένα παράθυρο `cmd(C:\Users\...\elasticsearch-9.2.0-windows-x86_64\elasticsearch-9.2.0\bin>elasticsearch)`, το οποίο παρέμεινε ανοιχτό καθόλη την διάρκεια που το πρόγραμμα έτρεχε, έτσι ώστε να μπορέσουμε να χρησιμοποιήσουμε την μηχανή αναζήτησης. Έπειτα, συνδεθήκαμε στην μηχανή αναζήτησης μέσω της εντολής: `client = Elasticsearch("http://localhost:9200")`
2. Προχωρήσαμε στο πρώτο ζητούμενο της εργασίας όπου ήταν η προεπεξεργασία των κειμένων ώστε αυτά να είναι κατάλληλα για να τα χρησιμοποιήσει η *elasticsearch*. Έτσι, χρησιμοποιήθηκε το σωστό encoding(`sys.stdout.reconfigure(encoding='utf-8')`) η συλλογή μετατράπηκε σε δομημένη μορφή JSON με *id* και κείμενο, όπου και δημιουργήθηκε το αρχείο `documents.json` από το αρχείο `documents.csv`. Η *elasticsearch* αναλαμβάνει την γλωσσική προεπεξεργασία (*stemming*, *stopwords* κλπ) μέσω του *analyzer* της, ώστε να διασφαλιστεί συνέπεια μεταξύ *indexing* και *querying* και να αξιοποιηθεί σωστά το BM25 οπότε δεν χρειάστηκε να κάνουμε κάτι παραπάνω.

```

{"ID": 193157, "Text": "Support towards the Europe PMC initiative-Contribution for 2014-2016: \The proposed action will provide continued support
{"ID": 193158, "Text": "Support to the Vice-Presidents of the ERC Scientific Council 2014: The proposed Action will provide the necessary support
{"ID": 193159, "Text": "Implementation of activities described in the Roadmap to Fusion during Horizon 2020 through a Joint programme of the membe
{"ID": 193160, "Text": "Monitoring Atmospheric Composition and Climate -III: MACC-III is the last of the pre-operational stages in the development
{"ID": 193161, "Text": "Pre-Operational Marine Service Continuity in Transition towards Copernicus: The main objective of the MyOcean Follow On pr
{"ID": 193162, "Text": "Underwater Time Of Flight Image Acquisition system: UTOFIA will offer a compact and cost-effective underwater imaging syst
{"ID": 193163, "Text": "European Union Contest for Young Scientists 2014: The European Union Contest for Young Scientists, an initiative of the Eu
{"ID": 193164, "Text": "Understanding Planet Mars With Advanced Remote-sensing Datasets and Synergistic Studies: The goals of the UPWARDS project
{"ID": 193177, "Text": "Light Night: The 20th Century was characterised by a tremendous growth in our capability to develop ever more sophisticate
{"ID": 193178, "Text": "Geometric problems in PDEs with applications to fluid mechanics: There are many high-profile problems in PDEs that ultim
{"ID": 193179, "Text": "European Researchers' Night in Madrid 2014-2015: Under the motto \u201cSupporting researchers, supporting the progress in
{"ID": 193180, "Text": "BIological therapy CYCLEs towards tailored, needs-driven, safer and cost-effective management of Crohn\u2019s disease: \The
{"ID": 193181, "Text": "EuroMix: Euromix aim to develop an experimentally verified, tiered strategy for the risk assessment of mixtures of multipl
{"ID": 193182, "Text": "Researchers in the Knowledge Triangle: The K-TRIO 2 consortium organized in several years Researchers\u2019 Night in Bulga
{"ID": 193183, "Text": "Strengthening Animal Production and Health through the Immune Response: SAPHIR aims to develop vaccine strategies effectiv
{"ID": 193184, "Text": "Conservative iron chelation as a disease-modifying strategy in Parkinson\u2019s disease: a multicentric, parallel-group, p
{"ID": 193185, "Text": "Toolless Manufacturing of Complex Structures: Lithography based additive manufacturing technologies (L-AMT) are capable of
{"ID": 193186, "Text": "Characterizing Atrial fibrillation by Translating its Causes into Health Modifiers in the Elderly: Atrial fibrillation (AF
{"ID": 193187, "Text": "Lunga notte della ricerca - Lange Nacht der Forschung 2014: In the alpine province of South Tyrol (500,000 inhabitants) sc
{"ID": 193188, "Text": "Optimizing and Enhancing the Integrated Atlantic Ocean Observing System: The overarching objective of AtlantOS is to achie
{"ID": 193189, "Text": "Aging Lungs in European Cohorts: This programme of work will advance the understanding of the combined effects of factors
{"ID": 193190, "Text": "NHM NIGHT5: Since 2010 NHM has successfully delivered four consecutive European Researchers\u2019 Nights with increasing p
{"ID": 193191, "Text": "Science@Aveiro, General public and researchers \u2013 Closing the Gap.: It\u2019s our intention to organize the 9th and 10
{"ID": 193192, "Text": "DREAMS European Researcher's Night: Sustainability means to create value by using resources in a responsible way to not je
{"ID": 193193, "Text": "Enthusiasm, Passion, Inspiration, Challenge (EPIIC) \u2013 Join us during the Researchers\u2019 Night and see for yourself
{"ID": 193194, "Text": "European Researchers' Night: Researchers' For a Better Future: The OurFuture: Researchers For a Better Future proposal con
{"ID": 193195, "Text": "EXPLORATHON - European Researchers' Night Scotland: We present a unique, pan-Scotland approach to high-impact researcher-l
{"ID": 193196, "Text": "Life is Science, Science is Life: LET'S DO THE SCIENCE!: Through the project, it is aimed to show public that researchers
{"ID": 193197, "Text": "European Researchers Night: Researchers in Real Life.: \u201cResearchers in Real Life\u201d is the project to show people

```

Μικρό στιγμιότυπο του αρχείου **documents.json**

3. Για το δεύτερο ζητούμενο της εργασίας δημιουργήσαμε ένα ευρετήριο μέσω της **elasticsearch**, όπου ως analyzer χρησιμοποιήσαμε τον κλασικό english και ως συνάρτηση ομοιότητας την BM25Similarity γιατί ήταν ο πιο απλός και ταυτόχρονα συμβατός τρόπος να δημιουργήσουμε το ζητούμενο ευρετήριο. Έτσι, το δημιουργήσαμε και το γεμίσαμε μέσω bulk με τα δεδομένα που είχαμε περάσει στο αρχείο **documents.json**.

```

59 # Creating an index with the mapping above
60 if client.indices.exists(index="my_texts"):
61     client.indices.delete(index="my_texts")
62 client.indices.create(index="my_texts", body=mapping)
63
64 # reading the jsonl file
65 documents = []
66 with open("documents.jsonl", "r", encoding="utf-8") as file:
67     for line in file:
68         data = json.loads(line)
69         documents.append({"_index": "my_texts",
70                           "_id": data["ID"],
71                           "_source": data})
72
73 # adding the texts into the index with bulk since we have a big dataset
74 bulk(client, documents, refresh=True)
75

```

Ο κώδικας της δημιουργίας του ευρετηρίου

4. Για το τρίτο ζητούμενο ανακτήσαμε για κάθε ερώτημα από το αρχείο **queries.csv** τα k πρώτα έγγραφα (k=20,30,50) χρησιμοποιώντας match queries. Τα αποτελέσματα αποθηκεύτηκαν σε αρχεία TREC format ώστε να είναι συμβατά με το εργαλείο **trec_eval**. Επαληθεύσαμε με αυτόν τον τρόπο ότι όχι μόνο το εργαλείο μπορεί να δεχτεί αυτή την μορφή αρχείου αλλά και ότι τα αρχεία είναι ταξινομημένα κατά query_id και το αρχείο αποτελεσμάτων είναι ταξινομημένο έτσι ώστε τα αποτελέσματα με το μεγαλύτερο similarity να δίνονται πρώτα για κάθε query. Για το

αρχείο documents.json επαληθεύεται η ταξινόμηση λόγω της λειτουργίας της *elasticsearch*. Έτσι, δημιουργήθηκαν 3 αρχεία: **results_20**, **results_30**, **results_50** με την εξής μορφή:

```
Phase1 > results_20.txt
```

1	Q01	Q0	193378	1	764.02673	myIRmethod
2	Q01	Q0	193373	2	273.72284	myIRmethod
3	Q01	Q0	205685	3	244.1519	myIRmethod
4	Q01	Q0	193715	4	242.06233	myIRmethod
5	Q01	Q0	206230	5	222.9547	myIRmethod
6	Q01	Q0	193353	6	222.53535	myIRmethod
7	Q01	Q0	193375	7	220.6753	myIRmethod
8	Q01	Q0	193386	8	216.5555	myIRmethod
9	Q01	Q0	211346	9	215.89311	myIRmethod
10	Q01	Q0	202703	10	213.50832	myIRmethod
11	Q01	Q0	206228	11	212.71326	myIRmethod
12	Q01	Q0	213250	12	212.42722	myIRmethod
13	Q01	Q0	194660	13	210.28812	myIRmethod
14	Q01	Q0	210137	14	207.94757	myIRmethod
15	Q01	Q0	213278	15	206.8191	myIRmethod
16	Q01	Q0	205643	16	206.60056	myIRmethod
17	Q01	Q0	211970	17	204.75098	myIRmethod
18	Q01	Q0	211972	18	199.05475	myIRmethod
19	Q01	Q0	206824	19	197.84494	myIRmethod
20	Q01	Q0	193402	20	197.28416	myIRmethod

Στιγμιότυπο ενός από τα αρχεία(*query_id Q0 doc_id rank score name*)

5. Στο τελευταίο βήμα χρησιμοποιήσαμε το εργαλείο αξιολόγησης *trec_eval* και τα μέτρα αξιολόγησης *MAP* (mean average precision) και *Precision@k* (ακρίβεια στα k πρώτα ανακτηθέντα κείμενα) για k = 5, 10, 15, 20 συγκρίνοντας τα αποτελέσματα μας με τις σωστές απαντήσεις του αρχείου **qrels.txt** παράγοντας τα αντίστοιχα αρχεία: **eval_20**, **eval_30**, **eval_50** τα οποία περιέχουν το *map* και το *precision* για καθένα από τα δοθέντα k. Η εντολή που χρησιμοποιήθηκε για την δημιουργία αυτών των αρχείων είναι ουσιαστικά η: **trec_eval -m map -m P.5,10,15,20 qrels.txt results_k.txt > eval_k.txt** όπου k={20, 30, 50}.

```
Phase1 > ≡ eval_20.txt
1  map all 0.6895
2  P_5 all 0.8800
3  P_10 all 0.7300
4  P_15 all 0.7000
5  P_20 all 0.6300
6  |
```

Το αρχείο `eval_20.txt` με τα αποτελέσματα του `trec_eval`

Πίνακας συνολικών αποτελεσμάτων του `trec_eval`:

	k=20	k=30	k=50
MAP	0.6895	0.7471	0.7701
P@5	0.8800	0.8800	0.8800
P@10	0.7300	0.7300	0.7300
P@15	0.7000	0.7000	0.7000
P@20	0.6300	0.6300	0.6300

Παρατηρούμε πως το `map` μεγαλώνει όσο μεγαλώνει και το πλήθος των εγγράφων και αυτό συμβαίνει λόγω του ότι εξετάζονται περισσότερα κείμενα και είναι αναμενόμενο. Το `precision` μένει σταθερό για κάθε k και αυτό επίσης είναι λογικό και δεν θα έπρεπε να αλλάζει εφόσον το $p < k$. Παρατηρούμε επίσης πως το `precision` μειώνεται όσο αυξάνεται το p και αυτό συμβαίνει γιατί τα κείμενα είναι ταξινομημένα κατά φθίνουσα σχετικότητα.

Τα αρχεία του φακέλου `Phase1` είναι:

`documents.csv` (μας παρέχεται και περιλαμβάνει τα κείμενα)

`queries.csv` (μας παρέχεται και περιλαμβάνει τα ερωτήματα)

`qrels.txt` (μας παρέχεται και περιλαμβάνει τις σωστές απαντήσεις)

`trec_eval.exe` (το εργαλείο αξιολόγησης)

`cyqwin1.dll` (απαραίτητο αρχείο του εργαλείου)

`phase1.py` (το πρόγραμμα μας όπου μπορούμε να το τρέξουμε και να πάρουμε τα παρακάτω αρχεία)

`documents.json` (το παράγει το πρόγραμμα και περιλαμβάνει τα επεξεργασμένα κείμενα)

`results_20` (το παράγει το πρόγραμμα και περιλαμβάνει τις απαντήσεις για τα 20 πρώτα ανακτηθέντα κείμενα)

`results_30` (το παράγει το πρόγραμμα και περιλαμβάνει τις απαντήσεις για τα 30 πρώτα ανακτηθέντα κείμενα)

`results_50` (το παράγει το πρόγραμμα και περιλαμβάνει τις απαντήσεις για τα 50 πρώτα ανακτηθέντα κείμενα)

eval_20 (το παράγει το πρόγραμμα και περιλαμβάνει τα αποτελέσματα της αξιολόγησης για τα 20 πρώτα ανακτηθέντα κείμενα)

eval_30 (το παράγει το πρόγραμμα και περιλαμβάνει τα αποτελέσματα της αξιολόγησης για τα 30 πρώτα ανακτηθέντα κείμενα)

eval_50 (το παράγει το πρόγραμμα και περιλαμβάνει τα αποτελέσματα της αξιολόγησης για τα 50 πρώτα ανακτηθέντα κείμενα)

Η εργασία πραγματοποιήθηκε κατά το χειμερινό εξάμηνο του έτους 2025-2026 στα πλαίσια του μαθήματος “Συστήματα Ανάκτησης Πληροφοριών” από τις φοιτήτριες του τμήματος Πληροφορικής στο Οικονομικό Πανεπιστήμιο Αθηνών, **Στυλιανή Μουμτζή (3220127)** και **Αναΐς Φαρχάτ (3220280)**.